



目 录

第1章 概 述

第2章 智能传感器系统中经典传感技术基础

第3章 不同集成度智能传感器系统介绍

第4章 智能传感器的集成技术

第5章 智能传感器系统智能化功能的实现方法

第6章 通信功能与总线接口

➤ 第7章 智能技术在传感器系统中的应用

第8章 智能传感器系统的设计与应用

第9章 无线传感器网络技术概述



第7章 智能技术在传感器系统中的应用 ——补充内容

要 点：

- ◆ 支持向量机技术在智能传感器中的应用；
- ◆ 粒子群优化算法在智能传感器中的应用。



§ 7.3 支持向量机技术在智能传感器中的应用

支持向量机SVM (Support Vector Machines)，主要用于传感器的动态建模、故障诊断、气体辨识和交叉灵敏度的消除等。

支持向量机通过定义不同的内积函数,可以实现多项式逼近、贝叶斯分类器、径向基函数、多层感知器等学习算法的功能。

支持向量机与神经网络方法类似，相对于多元回归分析法，不需要建立包括非目标参量在内的函数解析式，但均需由实验标定提供训练样本和检验样本，对于 k 个非目标参量，需要提供 $k+1$ 维的标定实验数据。



§ 7.3.1 基础知识

一、统计学习理论

基于数据的机器学习：

从观测数据出发，寻找研究对象的规律性，利用其规律性进行数学建模，并进而对未来的数据进行预测。

三种机器学习的实现方法：

◆ 经典的参数统计估计方法——传统统计学

缺点：要求研究的样本数目趋于无穷大，缺乏实用性。

◆ 经验非线性方法，如人工神经网络

两个方向：参数选择的优化算法；选择“最优”模型的统计测量方法。

◆ 基于统计学习理论的学习方法，如支持向量机和基于核的方法

专门研究小样本数据量情况下，机器学习规律性的理论。

统计学习理论研究的主要问题包括四个方面：



- 1) 基于经验风险最小化原则下统计学习一致性的充要条件。
- 2) 学习过程的收敛性及收敛速度。
- 3) 学习过程中收敛速度（推广能力）的控制。
- 4) 学习算法的构造

1、学习问题的一般性表示

学习：利用有限数量的观测数据来寻找待求的依赖关系。

最小化风险泛函：

$$R(\alpha) = \int Q(z, \alpha) dF(z), \alpha \in \Lambda$$

$F(z)$ ：空间 z 上的概率测度；

$\alpha = [\alpha_1, \alpha_2, \dots]$, $\alpha \in \Lambda$ ：参数集合；

$Q(z, \alpha)$ ：函数集合；

z ： z_1, z_2, \dots, z_l ，独立同分布数据。



测试误差的期望风险:

$$R(\alpha) = \int \frac{1}{2} |y - f(x, \alpha)| dP(x, y)$$

$P(x, y)$: 未知概率分布, 对应的 p 是其分布密度;

y : 与 x 相对应的实际值;

$f(x, \alpha)$: 与 x 相对应的理论值;

一个观测数量有限的训练集上的被测平均误差率——经验风险:

$$R_{emp}(\alpha) = \frac{1}{2l} \sum_{i=1}^l |y_i - f(x_i, \alpha)|$$

期望风险与经验风险的关系描述:

$$R(\alpha) \leq R_{emp}(\alpha) + \sqrt{\frac{h[\ln(2l / h) + 1] - \ln(\eta / 4)}{l}}$$



上式成立的概率： $1 - \eta$ ； $0 \leq \eta \leq 1$ ；

h ：非负整数，称为VC维， h 越大，学习机器的复杂性越高；
上式右边称为“风险界”，第2项称为“VC置信范围”。

2、VC (Vapnik Chervonenkis) 维

用于测量函数列的容量。

$$VC \dim(F) = \max \{h : N(F, h) = 2^h\}$$

$N(F, h)$ ： h 维向量中不同向量的个数。

3、结构风险最小化 (Structural Risk Minimization, SRM)

定义了在对给定数据逼近的准确性与逼近函数的复杂性之间的一种折中。



对于一定的 (p, τ_k) ，函数集合满足下列不等式：

$$\sup_{\alpha \in \wedge_k} \frac{(\int Q^p(z, \alpha) dF(z))^{1/p}}{\int Q(z, \alpha) dF(z)} \leq \tau_k, p > 2$$


这种结构称为容许结构，结构风险最小化原则就是在容许结构的嵌套函数集 S_k 中寻找一个合适的子集 S^* ，使结构风险达到最小，即：

$$\min_{S_k} R_{emp}(\alpha) + \sqrt{\frac{h[\ln(2l / h) + 1] - \ln(\eta / 4)}{l}}$$

4、建模误差

包括逼近误差和估计误差。

逼近误差因模型失配产生；估计误差因学习过程中选择了非优化模型所造成。这两个误差共同形成泛化误差。



结构风险最小化原理



二、支持向量机 (Support Vector Machine)

基于统计学习理论的一种新的通用机器学习方法，**基本思想**：

- ◆ 通过用内积函数定义的非线性变换将输入空间变换到一个高维特征空间；
- ◆ 在高维空间用线性函数假设空间寻找输入与输出之间的非线性关系；
- ◆ 学习算法基于结构风险最小化原则。

1、支持向量机的优点：


- ◆ 专门针对有限样本，求得在现有信息条件下的最优解；
- ◆ 通过二次型寻优，解决了神经网络方法中无法避免的局部极值问题；
- ◆ 通过非线性变换，保证学习机器有较好的推广能力，并使算法复杂度与样本维数无关。

2、支持向量机的结构

α_i : 拉格朗日乘子, $i=1, 2, \dots, s$;

b : 阈值或偏移量;

$K(x, x_i')$: 一个支持向量机的核函数;



支持向量机结构示意图



支持向量机通过核函数将输入空间的数据映射到高维的特征空间，在特征空间F中，通过线性回归函数进行数据的分类或拟合。

$$f(x) = \omega K(x, x'_i)^T + b$$

3、支持向量机的核函数：

建立核函数的目标是使得特征空间的维数不再影响计算，或在特征空间不需要进行内积计算。

定义 φ 为输入空间 X 到特征空间 F 的映射，若特征空间的内积与输入空间的核函数等价，即：

$$K(x, x') = \langle \varphi(x), \varphi(x') \rangle = \langle \varphi(x'), \varphi(x) \rangle$$

满足Mercer条件：

$$K(x, x') = \sum_m^{\infty} a_m \varphi_m(x) \varphi_m(x'), a_m \geq 0$$



$$\iint K(x, x')g(x)g(x')dxdx' > 0, g \in L_2$$

则核函数就能表征为特征空间中的一个内积。

4、核函数的种类

SVM的核函数不同，则SVM输出表达式及输出结果就不同。

1) 线性核

$$K(x, x_i) = \langle x, x_i \rangle$$

2) 多项式核

$$K(x, x_i) = (\langle x, x_i \rangle + p_2)^{p_1}$$

3) RBF核——高斯型径向基函数

$$K(x, x_i) = e^{-\frac{\|x - x_i\|^2}{2\sigma^2}}$$



4) Sigmoid (多层感知器) 核

$$K(x, x_i) = \tanh(p_1 \langle x, x_i \rangle + p_2), \tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

5) 张量积核

$$K(x, x_i) = \prod_{i=1}^n K_i(x, x_i)$$

5、支持向量机的种类:

1) SVC (支持向量分类)

用支持向量的方法描述分类的问题, 这里又分线性可分、线性不可分、非线性分类三种情形。

2) SVR (支持向量回归)

用支持向量的方法描述回归的问题, 分线性回归、非线性回归。



§ 7.3.2 支持向量机的训练、检验与测量

一、训练样本及检验样本的制备

在输入变量整个变化范围内根据需要确定标定点及数量，对实验标定所获得的样本数据 N ，将其分为两部分：训练样本 N_1 、检验样本 N_2 ，并使其格式相同，从而形成SVM的输入向量（样本）和输出向量（样本）：

$$\{[x_{i1}, x_{i2}, \cdots, x_{im}], y_i\}$$

二、支持向量机的训练

训练步骤：

1) 输入训练样本

训练样本（ N_1 个）作为支持向量， y 作为期望输出向量，并行输入支持向量机；



检验样本 (N_2 个) 作为特征空间向量, 串行输入支持向量机。

- 2) 设置SVM学习参数及核函数参数
- 3) SVM训练:

基于训练样本及真实风险最小化原则, 求出SVM结构参数 (权系数和偏移量)。若模型输出向量 $y(\mathbf{x})$ 与期望输出向量 \mathbf{y} 的差值最小, 则训练结束。

三、支持向量机的检验

将检验样本 (N_2 个) 作为输入向量输入训练好的支持向量机, 比较检验样本输出结果与期望的输出值, 若:

- 1) 在要求的误差范围内, 训练好的支持向量机满足使用要求;
- 2) 超出范围, 调整SVM学习参数及核函数参数, 重新训练;
- 3) 确定权系数 $\alpha_1, \alpha_2, \dots, \alpha_s$ 和偏移量 b , 即得到回归模型。



四、测量

由实际测量中获得的测量样本输入到SVM的输出表达式中，即可获得准确的待测量。

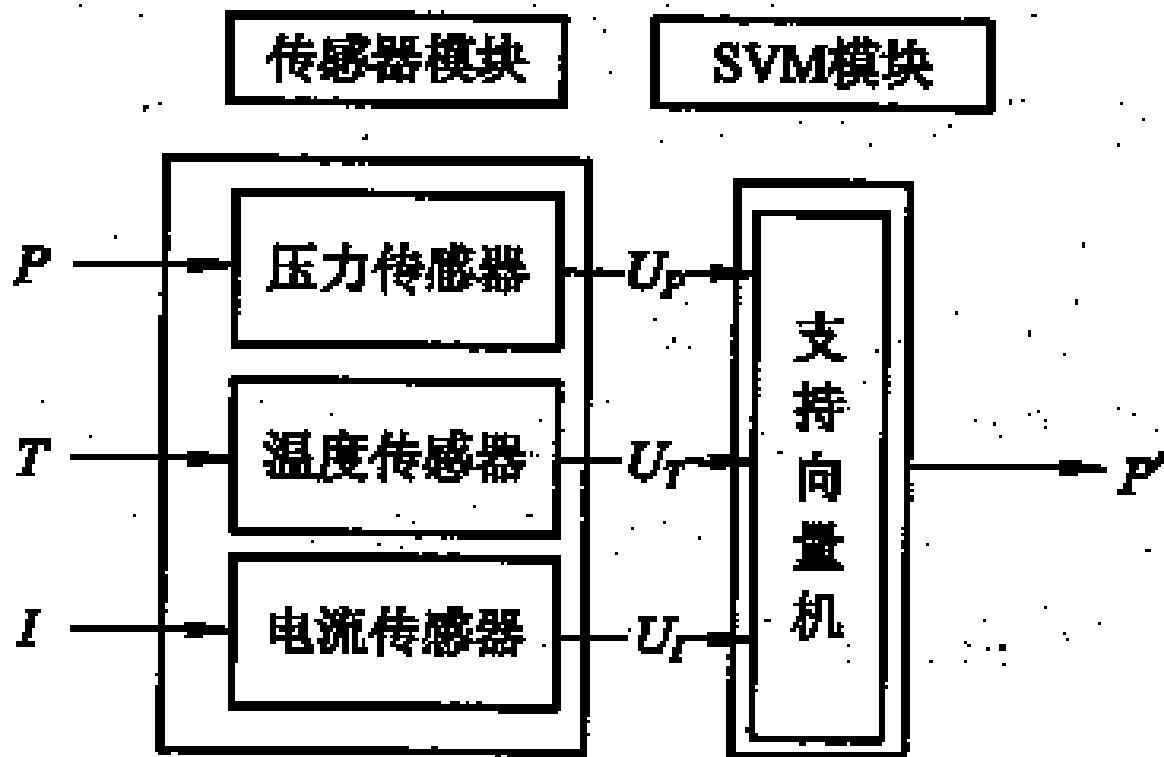
五、移植

经过训练并通过检验的支持向量机，将已知的权系数和偏移量代入SVM的输出表达式，根据所选用的硬件使用环境，进行软件编程实现，并通过实际运行，获得同样的使用效果。



§ 7.3.3 基于SVM方法的三传感器数据融合

一、系统组成




基于SVM的智能压力传感器系统框图



1、传感器模块

采用右图所示的检测电路，
分别获取压力、温度、电流信
号的电压输出值： U_P 、 U_T 、 U_I 。



2、支持向量机模块

$$y(x) = w^T x + b = \sum_{i=1}^s \alpha_i K(x, x'_i) + b$$

在上式中，通过多维标定实验获得 n 组样本： $\{[U_{Pi}, U_{Ti}, U_{Ii}], P'_i\}$ ；
输入向量的维数 $m=3$ ； x'_i 是从 n 组样本中取 s 组样本作为训练样本的支持向量；
 b 是SVM的阈值或偏移量； w 是SVM的权系数向量，数量为 s ； α_i 是与 x'_i 对应的拉格朗日乘子；



实际测量时， \mathbf{x} 代表被测输入向量，即： U_P 、 U_T 、 U_I ；而 y 代表期望输出标量 P ； $K(x, x_i')$ 是SVM的核函数。

二、示例1：降低两个干扰量影响的SVM功能模块的设计

采用Gaussian型RBF核函数的SVM作为其计算模型。

1、样本的制作

分学习（训练）样本、测试（检验）样本；

输入样本（三维）、输出样本（一维）。

2、编程实现

- 1) 利用Matlab平台进行设计、测试、验证；
- 2) 数据的预处理，根据需要确定是否进行归一化处理；
- 3) 支持向量机的参数；
- 4) 不同参数对输出结果的影响， σ 影响最大；



5) 对输入样本是否进行归一化处理, 使输出结果最佳的 σ 的最优值一般不一样。

3、SVM 融合输出结果及评价

核函数的参数 kerneloption (σ) 对融合输出结果的影响比较大, 需要反复测试, 才能找到合适的支持向量机的结构参数: w 、 b 。

评价参数	零位温度系数 α_0 (/°C)	灵敏度温度系数 α_1 (/°C)	电流影响系数 α_I (/mA)
融合前计算值	1.9×10^{-3}	1.2×10^{-2}	9.0×10^{-2}
$\sigma = 0.338$, Gaussian 型 RBF 核融合	2.1×10^{-4}	4.6×10^{-4}	3.6×10^{-4}
$\sigma = 10$, Gaussian 型 RBF 核融合	8.2×10^{-8}	6.1×10^{-4}	4.7×10^{-3}



4、移植

利用PC的强大计算功能，基于Matlab软件计算平台，进行支持向量SVM的训练，确定好训练合格支持向量SVM的结构参数、权系数 w 、偏置量 b 、RBF核参数 σ 。

将上述参数直接固化到单片机或DSP的内存中；同时用C语言改编上述实际运行程序为单片机或DSP 能够直接编译执行的程序并下载固化。

现场实际测量时，由下式求取融合后的数值：

$$y = \mathbf{w}\mathbf{x} + b$$



§ 7.4 粒子群优化算法在智能传感器中的应用

粒子群优化算法是近年来迅速发展的一种智能优化算法，与遗传算法有点类似，都是基于群体优化的方法，都是将系统初始化为一组随机数，通过迭代搜索最优值。但粒子群优化算法更简单、更容易实现，因此，目前已成为国际上优化领域新的研究热点。

在这里，我们结合参考教材里面的相关内容，对粒子群优化算法的基本概念、基本内容、具体应用做一个简要的介绍。



§ 7.4.1 粒子群优化算法概况

群智能 (Swarm Intelligence)

无智能或简单智能的主体通过任何形式的聚集协同而表现出智能行为的特性。

群智能的主要算法

两种主要算法：

1) 蚁群优化算法 (Ant Colony Optimization, ACO)

应用于组合优化问题，如：车辆调度、机器人路径规划、路由算法设计等。

2) 粒子群优化算法 (Particle Swarm Optimization, PSO)

应用于过程控制、图像识别、故障诊断等一些优化领域。

群智能算法的特点

1) 是一种能够有效解决大多数全局优化问题的新方法，而且方法简单，易于实现。



- 2) 应用领域包括：多目标优化、数据分类、聚类、模式识别、流程规划、信号处理、系统辨识、控制与决策等。
- 3) 仍然处于新兴发展与改进完善阶段。

§ 7.4.2 粒子群优化算法基础知识

粒子群优化算法源于人类对自然界生物群体行为研究的结果，通过计算机对动物复杂的群体行为进行仿真研究，建立起了微粒群算法的基本概念，其规则为：

- 1) 飞离最近的个体；
- 2) 飞向目标；
- 3) 飞向群体的中心。

个体学习与文化传递；信念的社会性及智能性；个性与社会性的平衡。



基本粒子群优化算法

粒子 i 在第 j 维子空间中运动的速度及位置:

$$v_{ij}(t+1) = v_{ij}(t) + c_1 r_{1j}(t)[p_{ij}(t) - x_{ij}(t)] + c_2 r_{2j}(t)[p_{gj}(t) - x_{ij}(t)]$$

$$x_{ij}(t+1) = x_{ij}(t) + v_{ij}(t+1)$$

$i = 1, 2, \dots, M$, M 是粒子的总数;

j : 表示微粒的第 j 维, 或称为算法优化的第 j 个参数;

c_1 : 认知参数, 又称加速因子, 取值范围: $0 \sim 2$;

c_2 : 社会参数, 又称加速因子, 取值范围: $0 \sim 2$;

r_{1j} : 随机函数, 在 $[0 \sim 1]$ 之间变化;

r_{2j} : 随机函数, 在 $[0 \sim 1]$ 之间变化;

p_{ij} : 为粒子个体 i 的历史最好解的第 j 维值;

p_{gj} : 为所有粒子在 t 时刻的历史最好解的第 j 维值。

$$p_{gj}(t) = \min \{ p_{ij}(t) \}$$



每次迭代，每个粒子根据目标函数计算其适应值大小，再根据适应值确定当前粒子最优位置 $p_{ij}(t)$ ，群体最优位置 $p_{gj}(t)$ ，再由上式调整各个粒子的速度及位置。

结束条件：

- 1) 迭代次数达到设定值，一般设为100；
- 2) 搜索到的最优位置满足预设的最小适应值，一般为零。

设 $f(x)$ 为最小化目标函数，微粒 i 的当前最好位置：

$$p_i(t+1) = \begin{cases} p_i(t), & f(x_i(t+1)) \geq f(p_i(t)) \\ x_i(t+1), & f(x_i(t+1)) < f(p_i(t)) \end{cases}$$

粒子数为 M 的群体最好位置：

$$\begin{aligned} p_g(t) &\in \{p_0(t), p_1(t), \dots, p_M(t)\} \mid f(p_g(t)) \\ &= \min \{f(p_0(t)), f(p_1(t)), \dots, f(p_M(t))\} \end{aligned}$$



为防止微粒在进化过程中离开搜索空间，对 v_{ij} 有范围限定：

$$v_{ij} \in [-v_{\max}, v_{\max}] \quad v_{\max} = k \bullet x_{\max}, 0.1 \leq k \leq 1.0$$

标准粒子群优化算法

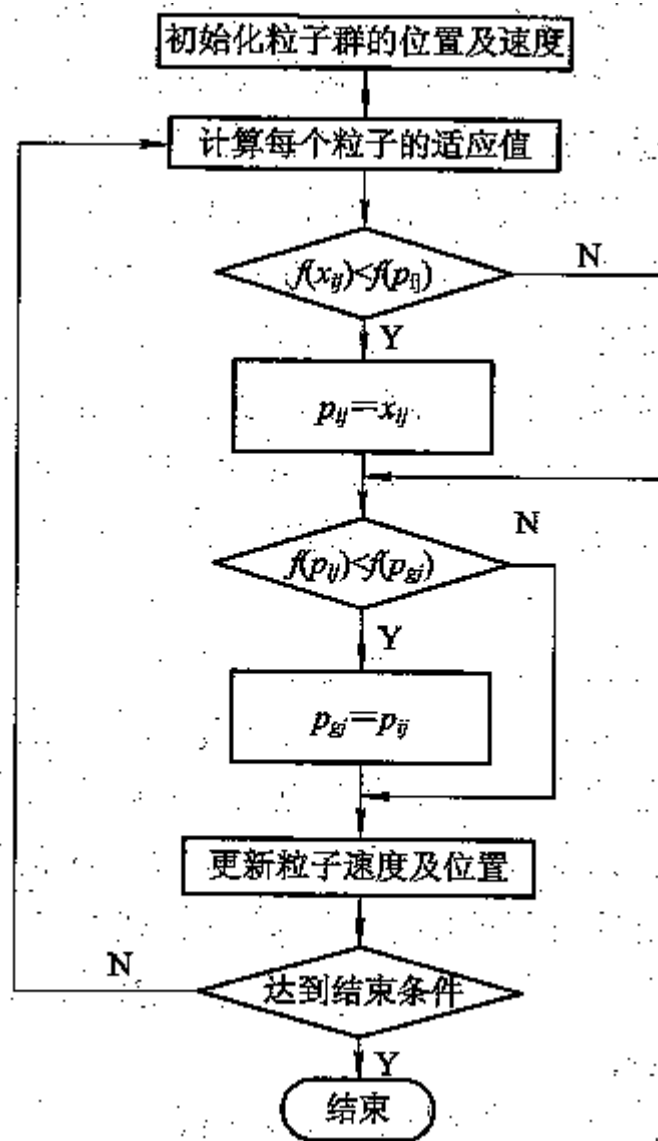
在基本PSO算法的基础上，引入了惯性权重因子，即：

$$v_{ij}(t+1) = wv_{ij}(t) + c_1r_{1j}(t)[p_{ij}(t) - x_{ij}(t)] + c_2r_{2j}(t)[p_{gj}(t) - x_{ij}(t)]$$

w 本身是非负实数，具有平衡全局和局部搜索能力的作用。在实际使用过程中，一般在（1，0）之间取值，由大到小逐渐变化。

粒子群优化算法流程

1) 初始化。在允许范围内随机设置粒子的初始位置、速度、群体最优值。



粒子群优化流程



2) 计算每个粒子的适应值或目标函数值（均方误差、方差、均方根误差）。

3) 将每个粒子的适应值与历史最优位置 p_{ij} 的适应值 $f(p_{ij})$ 进行比较，决定是否置换。

4) 将每个粒子的当前最优位置 p_{ij} 的适应值 $f(p_{ij})$ 与历史最优位置 p_{gj} 适应值 $f(p_{gj})$ 进行比较，决定是否置换。

5) 由上述计算结果更新粒子的速度和位置值。

6) 检查终止条件，若满足，终止迭代；否则返回2) 重复进行。



§ 7.4.3 粒子群优化算法的应用

以优化选取最小二乘法支持向量机（LS-SVM）中核函数参数 σ 及惩罚因子 C 为应用目标。

几种优化方法的比较：

评 价 参 数	零位温度系数 α_0 (/°C)	灵敏度温度系数 α_t (/°C)	电流影响系数 α_I (/mA)
模型校正前	1.4×10^{-3}	1.32×10^{-2}	8.91×10^{-2}
遍历优化	1.85×10^{-3}	2.54×10^{-3}	1.65×10^{-3}
PSO 优化一个参数	9.23×10^{-4}	2.04×10^{-3}	1.32×10^{-3}
PSO 优化两个参数	4.49×10^{-4}	3.89×10^{-4}	2.53×10^{-3}

这里的比较，是说明：通过粒子群优化算法，获得更精确的核函数参数 σ 及惩罚因子 C ，从而提高了支持向量机的融合精度。